


THE MIT WAY

Use os dados para tomar melhores decisões nos negócios. Tire o máximo proveito do Big Data em um curso online de 8 semanas do MIT.

**DATA SCIENCE E BIG
DATA: DECISÕES
BASEADAS EM DADOS**



Podemos usar nossos dados de maneira mais eficiente?

Cerca de 90% dos dados com os quais trabalhamos foram gerados nos últimos anos. Diante dessa avalanche de informação, as empresas se esforçam para extrair dos dados informações relevantes para que possam tomar decisões mais assertivas em seus negócios.

Com o propósito de ajudar a revelar o verdadeiro valor dos dados, o IDSS (Institute for Data, Systems and Society) do MIT criou o curso online “Ciência de Dados e Big Data: Decisões Baseadas em Dados”, voltado para profissionais de ciência de dados que buscam aproveitar os dados de maneira inovadora.

Durante oito semanas, sua habilidade para analisar dados estará em um novo patamar, à medida em que aprende a teoria e a prática relacionadas a sistemas de recomendação, regressões, modelos de rede e gráficos, detecção de anomalias, testes de hipótese, aprendizagem de máquina e análise de big data.


Com os professores do MIT, você descobrirá o impacto que o big data tem sobre a tomada de decisões.

A QUEM SE DIRIGE

Profissionais em qualquer estágio da carreira que precisam converter grandes conjuntos de dados em informações que possam ser processadas.

Entre os estudantes que já passaram pelo curso, há analistas de inteligência empresarial, consultores de gestão e gerentes das áreas de negócios e ciências de dados.

Entusiastas da ciência de dados e profissionais de TI.

**Duração**

8 semanas

**Tempo de
dedicação**

5 a 7 horas por
semana

**Modalidade**

Online

**Créditos
(CEUs)**

1,8

DEPOIS DESTA CURSO, VOCÊ PODERÁ:

- ✓ Aplicar técnicas de ciência de dados para enfrentar os desafios decorrentes da gestão de dados em uma empresa.
- ✓ Determinar a diferença entre modelos gráficos e modelos de rede.
- ✓ Converter conjuntos de dados em modelos a partir da análise preditiva.
- ✓ Implementar algoritmos de aprendizagem de máquina para tomar melhores decisões de negócios.
- ✓ Dominar as melhores práticas para a concepção de experimentos e testes de hipóteses.
- ✓ Identificar e evitar os erros comuns na análise de *big data*.

PROGRAMAÇÃO DO CURSO

SEMANA 1

Módulo 1: Dar sentido a dados não estruturados

FACULTY LEADS:

Stefanie Jegelka e Tamara Broderick

Los participantes aprenderán:

Ao final do módulo, os participantes deverão ser capazes de saber:

1. A diferença entre a aprendizagem supervisionada e a aprendizagem não supervisionada.
2. Como aplicar técnicas de classificação e agrupamento.
3. Como funciona o algoritmo K-médias e como implementá-lo.
4. O que são modelos de pertinência mista e mapeamento de atributos.
5. O que é a Análise de Componentes Principais (PCA) e como calculá-la por meio dos autovetores.
6. O que é agrupamento espectral e modularidade, assim como o termo representação.

Questionário inicial obrigatório e não avaliável
(Responda ao questionário para ver o conteúdo do curso).

Introdução

Agrupamento (Tamara Broderick)

Estudos de caso:

- Estudo de caso 1: Códigos genéticos
- Estudo de caso 2: Encontrar temas na descrição do projeto

Atividades avaliáveis:

Realize a atividade do módulo 1.1
(data de entrega: final do curso)

Agrupamento espectral, componentes e inserções (Stefanie Jegelka)

Estudos de caso:

- Estudo de caso 3: ACP: identificação de rostos
- Estudo de caso 4: Agrupamento espectral: agrupamento de notícias

Atividades avaliáveis:

Realize a atividade do módulo 1.2
(data de entrega: final do curso)

SEMANA 2 e 3

Módulo 2: Regressão e previsão

FACULTY LEADS:
Victor Chernuzkov

Ao final do módulo, os participantes deverão ser capazes de:

1. Reconhecer um problema de regressão.
2. Propor um modelo adequado com objetivo de inferência.
3. Diferenciar correlação e causalidade.
4. Identificar contextos de dimensões altas.
5. Selecionar o método apropriado para um contexto de dimensões altas.
6. Compreender as limitações dos estudos observacionais para inferência causal, com ênfase especial no fator de confusão.
7. Distinguir e implementar ensaios clínicos randomizados e fazer inferências causais neles.

Regressões e extensões lineares e não lineares clássicas

Estudos de caso:

- Estudo de caso 1: Prever salários 1
- Estudo de caso 2: Diferença salarial por gênero

Regressão moderna com dados de alta dimensão

Estudos de caso:

- Estudo de caso 3: Os países pobres crescem mais rápido que os ricos?

O uso da regressão moderna para a inferência causal

Testes controlados aleatorizados

Estudos observacionais com fatores de confusão

Estudos de caso:

- Estudo de caso 4: Prever salários 2
- Estudo de caso 5: O efeito da posse de armas nas taxas de homicídios

Atividades avaliáveis:

Realize a atividade do módulo 2
(data de entrega: final do curso)

SEMANA 4

Módulo 3.1 Classificação e verificação de hipóteses

FACULTY LEADS:
**David Gamarnik e
Jonathan Kelner**

Os participantes deverão ser capazes de:

1. Assimilar os princípios da detecção de anomalias.
2. Formular um problema de teste de hipóteses.
3. Compreender o conceito de valor p.
4. Descrever vários algoritmos de aprendizagem de máquina para classificação.

Classificação e verificação de hipóteses

Estudo de caso:

Estudo de caso 1: Regressão logística - O acidente do Challenger

Atividades avaliáveis:

Realize a atividade do módulo 3.1
(data de entrega: final do curso)

SEMANA 5

Módulo 3.2 Aprendizagem profunda

FACULTY LEADS:
Víctor Chernuzkov

Objetivos:

1. Compreender o conceito de aprendizagem profunda.
2. Descrever a retropropagação.

Estudo de caso:

Estudo de caso 2: Limite de decisão de uma rede neural profunda

Atividades avaliáveis:

Realize a atividade do módulo 3.2
(data de entrega: final do curso)

SEMANA 6

Módulo 4 Sistemas de recomendação

FACULTY LEADS:
Devavrat Shah e
Phillipe Rigollet

Objetivos:

1. Saber distinguir a previsão tradicional dos sistemas de recomendação.
2. Saber distinguir recomendações baseadas no usuário de recomendações baseadas em itens.
3. Descrever as configurações sob as quais a Decomposição em valores singulares (Singular Value Decomposition, SVD) funciona corretamente.
4. Identificar sistemas de recomendação com diferentes tipos de dados.
5. Usar a aprendizagem ativa (active learning) para compilar dados de forma eficiente.
6. Estar ciente da variedade de princípios nos quais os sistemas de recomendação se apoiam. inferências causais neles.

Recomendações e *ranking*

Filtragem colaborativa

Estudos de caso:

- Estudo de caso 1: Recomendar filmes (avaliável)
- Estudo de caso 2: Recomendar novas canções a usuários em função do que costumam ouvir
- Estudo de caso 3: Fazer recomendações de novos produtos

Conclusão:

- Pautas sobre o sistema de construção
- Observações e desafios finais

Atividades avaliáveis:

- Realize a atividade do módulo 4 (data de entrega: final do curso)
- Estudo de caso avaliável: Resolução e envio
- Estudo de caso avaliável: Revisão e envio do trabalho de três colegas
- Resolução e envio de seu estudo de caso (data de entrega: até às 23:59 do domingo posterior a aula)
- Revisão e envio do trabalho de seu colega (data de entrega: até às 23.59 do dia seguinte ao recebimento do trabalho)

FACULTY LEADS:**Caroline Uhler e Guy Bresler****Os participantes deverão ser capazes de reconhecer:**

1. Quando estão lidando com dados de rede ou quando uma rede é o melhor caminho para representar alguns dados.
2. Vários modelos de rede e suas dinâmicas.
3. Vários algoritmos presentes nas redes.
4. Os fundamentos dos modelos de grafo.
5. As limitações da aprendizagem dos efeitos causais dos dados observacionais.

Introdução**Redes****Modelos gráficos****Estudos de caso:**

- Estudo de caso 1: Navegação/GPS
- 1.1 Filtro de Kalman: Acompanhamento da posição 2D de um objeto quando se move a velocidade constante
- 1.2 Filtro de Kalman: Acompanhamento da posição 3D de um objeto quando se move a velocidade constante
- Estudo de caso 2: Identificar novos genes que causam autismo

Atividades avaliáveis:

Realize a atividade do módulo 5
(data de entrega: final do curso)

FACULTY LEADS:**Kalyan Veeramachaneni****Os participantes deverão ser capazes de:**

1. Reconhecer quando estão trabalhando com dados temporais em contraste com dados que não são dependentes do tempo.
2. Definir corretamente os exemplos de treinamento e as variáveis de saída.
3. Conhecer vários algoritmos para a aprendizagem de features (feature learning).
4. Conhecer as bases da seleção de modelos e as suas diversas técnicas.

Certificado do curso:

Obtenha o certificado do curso do MIT e 1,8 CEUs (disponível para descarrega por meio da plataforma 24h após ao término do curso)

Acesso ao curso:

Acesso durante 3 meses após a finalização do curso

Modelagem preditiva para dados temporários**Engenharia de fatores****Estudos de caso:**

- Estudo de caso 1: NYC Taxi (avaliável)
- Estudo de caso 2: Conjunto de dados de comerciantes do Reino Unido

Atividades avaliáveis:

Completar TODAS as atividades (data de entrega: final do curso)

Estudo de caso avaliável:

- Resolução e envio de seu estudo de caso (data de entrega: até às 23:59 do domingo posterior a aula)
- Revisão e envio do trabalho de seu colega (data de entrega: até às 23:59 do domingo posterior a aula)

Atividades obrigatórias:

Realize o questionário final
(data de entrega: último dia do curso)